

基于多策略改进麻雀算法优化 SVM 的齿轮箱故障诊断

任远芳¹, 余升亮², 谢 刚³, 丁 静⁴, 卿江萍⁵, 张思聪⁶

(1. 贵州大学 网络与信息化管理中心, 贵州 贵阳 550025; 2. 内蒙古工业大学 电力学院, 内蒙古 呼和浩特 010051; 3. 贵州思大教育科技有限公司, 贵州 贵阳 550025; 4. 贵州大学 教务处, 贵州 贵阳 550025; 5. 邵阳职业技术学院 信息技术学院, 湖南 邵阳 422004; 6. 贵州师范大学 网络空间安全学院, 贵州 贵阳 550025)

摘要: 齿轮箱作为机械传动系统中的关键部件, 其故障诊断对设备安全运行具有重要意义。针对齿轮箱早期故障信号微弱, 故障诊断准确率低的问题, 提出了一种基于变分模态分解和多策略改进麻雀算法优化支持向量机的齿轮箱故障诊断方法。首先, 利用 VMD 对齿轮箱振动信号进行分解, 以提取多尺度特征信息。其次, 提出一种多策略改进的麻雀优化算法, 通过引入拉丁超立方、自适应权重因子、可变螺旋搜索以及莱维飞行策略, 提升算法的全局搜索能力和收敛速度, 并将其应用于 SVM 超参数寻优。最后, 利用优化后的 SVM 模型对齿轮箱故障类型进行诊断。实验表明, 基于 VMD 和多策略改进麻雀算法优化的 SVM 模型在齿轮箱故障诊断中表现出更高的分类精度和稳定性。

关键词: 故障诊断; 变分模态分解; 支持向量机; 麻雀优化算法

中图分类号: TP181 **文献标识码:** A **文章编号:** 1673-6125(2025)03-0088-08

DOI: 10.16856/j.cnki.52-1142/n.2025.03.012

Optimization of SVM for Gearbox Fault Diagnosis Based on Multi-Strategy Improved Sparrow Algorithm

REN Yuanfang¹, YU Shengliang², XIE Gang³, DING Jing⁴, QING Jiangping⁵, ZHANG Sicong⁶

(1. Network and Information Technology Management Center, Guizhou University, Guizhou, Guiyang 550025; 2. School of Electric Power, Inner Mongolia University of Technology, Neimenggu, Hohhot 010051; 3. Guizhou Sida Education Technology Co., Ltd., Guizhou, Guiyang 550025; 4. Academic Affairs Office, Guizhou University, Guizhou, Guiyang 550025; 5. Institute of Information Technology, Shaoyang Polytechnic, Hunan, Shaoyang 422004; 6. School of Cyber Science and Technology, Guizhou Normal University, Guizhou, Guiyang 550025)

Abstract: Gearbox is a key component in mechanical transmission systems. Gearbox fault diagnosis is of great significance for the safe operation of equipment. Aiming at the problems of weak early fault signals and low accuracy of fault diagnosis for gearboxes, this paper proposes a fault diagnosis method for gearboxes. The method is based on variational modal decomposition (VMD) and multi-strategy improvement of sparrow algorithm optimized support vector machine (SVM). Firstly, VMD is used to decompose the gearbox vibration signal to extract multi-scale feature information and enhance the identification ability of fault features. Secondly, an improved sparrow search algorithm is designed to enhance the global search capability and convergence speed of the algorithm by introducing adaptive weight factors, varia-

收稿日期: 2024-10-18

基金项目: 贵州省科技计划项目“基于大数据技术与自然语义分析处理技术的民事虚假诉讼(套路贷)监督研判分析关键技术研究”(黔科合支撑[2023]一般 449); 贵州大学校级教改项目“基于智慧课堂的基础学科教学现状与对策研究”(XTG2023075); 贵州省教育科学规划课题“区域教学共同体视域下贵阳市中学人工智能教学实施路径与策略研究”(2021B031)。

作者简介: 任远芳, 女, 实验师, 硕士。研究方向: 计算机、多媒体教学。

余升亮, 男, 研究生。研究方向: 检测技术与自动化装置。

ble spiral search and Levy flight strategy. And the improved algorithm is used to optimize the parameters of the SVM model. Finally, the optimized SVM model is used to classify and diagnose gearbox fault types. The experimental results show that the optimized SVM model based on VMD and multi-strategy improvement of sparrow algorithm exhibits high classification accuracy and stability in gearbox fault diagnosis. This model is significantly better than the traditional SVM model and other optimization algorithms, and verifies the effectiveness and superiority of the method.

Keywords: Gearbox fault diagnosis; Variational modal decomposition; Support vector machine; Sparrow algorithm

在工业领域,由于齿轮箱工作环境差,易受摩擦、振动等多种因素的影响,使得故障和失效的风险增加^[1-2],因此,齿轮箱故障诊断对于生产安全尤为重要。近年来,信号处理方法在齿轮箱振动信号特征提取方面得到了广泛应用,其中,经验模态分解(EMD)、集合经验模态分解(EEMD)和变分模态分解(VMD)等方法被广泛应用于信号特征提取和降噪处理^[3]。赵化彬和闫鹏等使用 EMD 对振动信号进行处理以达到降噪目的,但是用 EMD 处理后的信号会存在模态混叠现象,影响后续信号分析效果^[4-5]。Yixin 等^[6]使用 EEMD 处理振动信号,但是存在产生虚假本征模态分量的问题。相比之下,VMD 具有更稳健的数学理论基础,并能够自适应地分解信号为若干本征模态函数(IMF),无需预先设定模态数目,适合复杂非线性和非平稳信号的处理。高川和蔡铮印等通过 VMD 算法,选取合适的 IMF 分量重构成最优特征信号,提升了故障识别率^[7-8]。

机器学习算法也被广泛应用于故障诊断领域^[9]。支持向量机(SVM)因其良好的泛化能力被广泛应用^[10],然而,SVM 的分类性能受超参数选择的影响较大,传统的网格搜索或人工调参方法难以获得最优结果,为此,研究者们提出了多种智能优化算法来优化 SVM 参数^[11-13],其中粒子群优化算法(PSO)对参数设置敏感,导致收敛速度较慢。金枪鱼群优化算法(TSO)和天鹰优化算法(AO)存在容易陷入局部最优和收敛精度不高的问题。相比之下,麻雀优化算法(SSA)具有更强的全局搜索能力和更快的收敛速度,但仍会面临陷入局部最优和初始化种群不均匀等问题。

针对以上问题,本文选择 VMD 作为信号处理和特征提取的方法,并提出一种多策略改进的麻雀搜索算法 MSISSA。在此基础上构建出 MSISSA-SVM 故障诊断模型,将经过 VMD 分解的 IMF 分量对其计算均值、方差、峰值、峭度、有效值、峰值因子、脉冲因子、波形因子和裕度因子 9 个指标,进行信号重构后输入到 MSISSA-SVM 模型进行故障

诊断,实验表明该方法有着更高的诊断精度。

1 理论介绍

1.1 变分模态分解

VMD 是 Dragomiretskiy 于 2014 年提出的一种信号处理方法^[9]。它能够自适应地将复杂信号分解成多个具有窄带频谱特征的 IMF 分量,其具体步骤为:

(1) 构建 VMD 约束变分模型可表示为:

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_k \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \\ \text{s. t. } \sum_k u_k(t) = f(t) \end{cases} \quad (1)$$

式(1)中, k 为模态分量的解析信号数; u_k 为原始信号分解的模态分量; $f(t)$ 为输入信号; $\delta(t)$ 为狄拉克分布函数; ∂_t 为偏导的运算符号; $[\delta(t) + \frac{j}{\pi t}] * u_k(t)$ 为 $u_k(t)$ 的希尔伯特变换。

(2) 利用二次惩罚因子和拉格朗日函数引入求解过程,将约束变分模型转化成非约束变分模型:

$$L(\{u_k\}, \{\omega_k\}, \lambda) = \alpha \sum_k \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \left\| f(t) - \sum_k u_k(t) \right\|_2^2 + \langle \lambda(t), f(t) - \sum_k u_k(t) \rangle \quad (2)$$

(3) 通过交替方向乘子法交替更新 u_k^{n+1} 、 w_k^{n+1} 、 λ_k^{n+1} ,求得拉格朗日表达式的“鞍点”表达式为:

$$u_k^{n+1}(w) = \frac{f(w) - \sum_{i \neq k} u_i^n(w) + \frac{\lambda(w)}{2}}{1 + 2\alpha(w - \omega_k)^2} \quad (3)$$

$$\omega_k^{n+1} = \frac{\int_0^\infty w |u_k(w)|^2 dw}{\int_0^\infty |u_k(w)|^2 dw} \quad (4)$$

$$\lambda^{n+1}(w) = \lambda^n(w) + \tau \left(f(w) - \sum_k u_k^{n+1}(w) \right) \quad (5)$$

(4) 当分解模态满足式(6), 则迭代停止。

$$\sum_k \|u_k^{n+1} - u_k^n\|_2^2 / \|u_k^n\|_2^2 < \varepsilon \quad (6)$$

1.2 支持向量机

SVM 是一种解决分类问题的机器学习算法。按输入数据是否线性, SVM 可分为线性 SVM 和非线性 SVM。

线性 SVM, 求解目标如下式所示:

$$s. t. y_i(w^T x_i + b) \geq 1 \quad (i = 1, 2, \dots, m) \quad (7)$$

若数据线性不可分, 需引入松弛变量。

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (8)$$

约束条件为:

$$s. t. y_i(w^T x_i + b) \geq 1 - \xi_i \quad (9)$$

式(7)~(9)中, w 为权重向量; b 为偏置向量; x_i 表示第 i 个特征向量; y_i 表示样本类别; C 为惩罚因子。

为了使线性不可分数据线性可分, 需引入核函数将其映射到高维空间, 选用径向基核函数, 其公式如下:

$$K(m, n) = \exp\left(-\frac{\|m - n\|^2}{2\sigma^2}\right) \quad (10)$$

其中, σ 表示核函数的宽度, 且 $\sigma > 0$; $\|m - n\|^2$ 表示样本点 m, n 间的距离。

2 麻雀优化算法及其改进

2.1 麻雀优化算法

SSA 模拟了麻雀的捕食、反捕食行为, 其主要有发现者、加入者和警戒者三种角色, 通过信息共享和共同协作寻求全局最优解。这三种角色的更新法则及公式如下所示。

更新发现者位置, 公式如下:

$$X_{i,j}^{t+1} = \begin{cases} X_{i,j}^t \cdot \exp\left(-\frac{i}{a \cdot item_{\max}}\right) & R_2 < ST \\ X_{i,j}^t + Q \cdot A & R_2 \geq ST \end{cases} \quad (11)$$

式(11)中, t 为当前迭代数, $j = 1, 2, 3, \dots, n$; $item_{\max}$ 为最大迭代次数; $X_{i,j}$ 为第 i 个麻雀在维度 j 中的位置, $a \in (0, 1]$ 。预警值 $R_2 \in [0, 1]$ 。安全阈值 $ST \in [0.5, 1.0]$; Q 服从正态分布; A 代表

一个元素均为 1 的 $1 \times n$ 矩阵。

当 $R_2 < ST$ 时, 意味着此时周围无捕食者, 发现者可向更大范围进行搜索。若 $R_2 \geq ST$ 时, 这意味着有部分麻雀发现捕食者, 并发出相应警报, 通知所有麻雀迅速飞往其他安全地方。

加入者的位置更新按照如下公式:

$$X_{i,j}^{t+1} = \begin{cases} Q \cdot \exp\left(\frac{X_{worst}^t - X_{i,j}^t}{i^2}\right) & i > n/2 \\ X_p^{t+1} + |X_{i,j}^t - X_p^{t+1}| A^+ \cdot L & otherwise \end{cases} \quad (12)$$

式(12)中, X_p 、 X_{worst} 分别为发现者当前所占据的最优位置、全局最差位置。A 表示一个 $1 \times n$ 的矩阵, 且随机将 1 或 -1 赋值给每个元素。若 $i > n/2$ 时, 表示第 i 个加入者的适应度值较低, 没有获得食物, 为了觅食, 获取更多的能量, 它将飞往其它地方; 若 $i \leq n/2$ 时, 表示这些加入者有机会靠近当前发现者最优位置。

警戒者的位置更新公式如下:

$$X_{i,j}^{t+1} = \begin{cases} X_{best}^t + \beta \cdot |X_{i,j}^t - X_{best}^t| & f_i > f_b \\ X_{i,j}^t + K \cdot \left(\frac{|X_{i,j}^t - X_{worst}^t|}{(f_i - f_w) + \varepsilon}\right) & f_i = f_b \end{cases} \quad (13)$$

式(13)中, X_{best} 表示当前全局最佳位置; 步长控制参数 $\beta \sim N(0, 1)$; K 是步长控制参数, 且属于 $[-1, 1]$; f_i 为第 i 个麻雀目前适应度值; f_b 、 f_w 分别表示当前全局范围内最佳、最差的适应度值。 ε 为趋近于 0 的常数。

2.2 改进的麻雀优化算法

为使种群分布更均匀、加快收敛速度并不易陷入局部最优, 本文引入拉丁超立方、自适应权重因子、可变螺旋搜索及莱维飞行策略, 对 SSA 进行改进, 具体改进方法为:

(1) 基于拉丁超立方的种群初始化

为减小 SSA 中初始化种群的随机性, 采用具有均匀分层特征的拉丁超立方策略初始化种群, 保证了全空间填充和抽样点非重叠。拉丁超立方策略包含三个步骤^[14]:

1) 确定抽样规模 N 和变量的维数 m , 将每个变量的上下限区间 $[x_{il}, x_{ih}]$ 划分成 N 个相等的小区间, 得到 N^m 个小超立方体。

2) 创建一个 $N \times m$ 的矩阵 A, 对于每个变量, 生成数列 $\{1, 2, \dots, N\}$ 的一个随机全排列, 并填入

矩阵 A 的每一列。

3) 矩阵 A 的每行对应一个小超立方体,在每个小超立方体内随机生成一个样本,共有 N 个样本被选出,且选出的样本互不相同。

(2) 基于自适应加权策略的发现者位置更新

在整个麻雀种群中,发现者引导其他个体寻找食物,为提高发现者位置质量,增强 SSA 的局部及全局搜索能力,在发现者阶段引入一个实时变化的惯性权重 ω ,表示为:

$$\omega(t) = 0.2 \cdot \cos\left(\frac{\pi}{2} \cdot \left(1 - \frac{t}{iter_{max}}\right)\right) \quad (14)$$

式(14)中, ω 在 $[0,1]$ 非线性变化。

将权重值 ω 用于改进发现者位置公式,具体如式(15)所示:

$$X_{i,j}^{t+1} = \begin{cases} \omega(t) \cdot X_{i,j}^t \cdot e^{-\frac{t}{a \cdot M}} & R_2 < ST \\ \omega(t) \cdot X_{i,j}^t + Q \cdot A & R_2 \geq ST \end{cases} \quad (15)$$

(3) 基于莱维飞行策略的警戒者位置更新

莱维飞行是一种随机搜索方式。在保留较长距离变动能力的情况下,这种策略能促使麻雀在局部范围内做小规模移动。模拟莱维分布的算法是 Mantegna 算法,步长计算公式如下:

$$s = \frac{m}{|n|^{\frac{1}{\alpha}}} \quad (16)$$

式(16)中, α 为莱维飞行步长的参数, $\alpha \in (1, 3]$, 通常为 1.5; m 、 n 为随机数,且服从正态分布,

$$m \sim N(0, \sigma_m^2), n \sim N(0, \sigma_n^2) \quad (17)$$

其中,

$$\sigma_m = \left\{ \frac{\Gamma(1+\alpha) \sin \frac{\pi\alpha}{2}}{\Gamma(\frac{1+\alpha}{2}) \alpha \times 2^{\frac{\alpha-1}{2}}} \right\}^{1/\alpha} \quad \sigma_n = 1 \quad (18)$$

融入莱维飞行策略的警戒者位置更新公式如下:

$$X_j(t) = X_j(t) + L \oplus \text{levy}(\lambda) \quad (19)$$

式(19)中, $X_j(t)$ 为第 j 个麻雀在第 t 次迭代时的位置; \oplus 为计算符号,即点对点乘法; L 表示为步长控制参数。

$$L = 0.01s \quad (20)$$

(4) 基于可变螺旋搜索策略的加入者位置更新

加入者位置更新仅依赖于发现者的位置信息时效率较低。受鲸鱼算法中螺旋搜索因子启发,在加入者群体中引入可变螺旋位置更新策略,其螺旋搜索因子的公式如式(21)所示:

$$\begin{cases} \varphi = e^{z l} \cdot \cos(2\pi l) \\ z = \exp\left(k \cdot \cos\left(\pi \cdot \frac{np - i}{np}\right)\right) \end{cases} \quad (21)$$

式(21)中, z 为基于 e 指数函数组成的螺旋参数。均匀分布随机数 $l \in [-1,1]$; k 为变化系数。加入者的位置更新公式为:

$$X_{i,j}^{t+1} = \begin{cases} \varphi \cdot Q \cdot \exp\left(\frac{X_{i,j}^t - X_{i,j}^t}{i^2}\right) & i > n/2 \\ X_{i,j}^{t+1} + |X_{i,j}^t - X_{i,j}^{t+1}| \cdot A^+ \cdot L \cdot \varphi & \text{otherwise} \end{cases} \quad (22)$$

由式(22)可知,可变螺旋搜索策略既促使加入者位置更新的方式更灵活、更新路径更多,又兼顾了整个算法全局搜索及局部搜索的平衡。

2.3 MSISSA 优化 SVM 流程

MSISSA 用于优化 SVM 的超参数,然后使用优化后的 SVM 模型对齿轮箱故障进行分类,其具体实现流程如下:

(1) 初始化麻雀种群。设置种群的大小,发现者数量比例及警戒者所占比例,迭代次数的最大值等。通过拉丁超立方策略改进种群初始化,得到位置均匀的种群。

(2) 设定参数,包括寻优的参数个数及参数的上下限等。

(3) 计算比较并记录所有麻雀的位置,并计算它们每一只的适应度值、排序,识别出最优、最差的适应度值。

(4) 根据公式(15)和(19)分别更新发现者、警戒者位置。

(5) 根据公式(22)更新加入者位置。

(6) 不断迭代更新,计算每一次迭代后的适应度值。若优于当前位置,保留最优适应度值对应位置。

(7) 通过判断目前是否达到最大迭代次数。若未达到,就返回步骤(3)。否则进行下一步骤。

(8) 记录并输出最优参数。按照最优参数构建 SVM 诊断模型。

3 实验及结果分析

3.1 MSISSA 算法性能测试实验

为验证 MSISSA 算法性能,选取 cec2005 测试函数中具有代表性的 F1 ~ F6 函数进行寻优实验,将 MSISSA 与 PSO、DBO、SSA 进行对比实验。实验设置种群维度为 50,最大迭代次数为 500,以上测试函数独立运行 30 次。实验结果如表 1 所示。

表 1 四种算法的性能测试结果比较

函数	函数值	MSISSA	SSA	DBO	PSO
F1	平均值	0	7.718 9E-135	2.717 9E-110	4.938 13E-11
	标准差	0	4.227 8E-134	1.488 6E-109	1.069 83E-10
	最优值	0	0	5.246 6E-171	1.181 27E-12
F2	平均值	6.207 1E-289	8.712 13E-78	4.259 27E-52	3.795 81E-07
	标准差	0	3.875 34E-77	2.332 89E-51	3.636 35E-07
	最优值	0	0	6.525 15E-88	5.734 13E-08
F3	平均值	0	5.238 76E-83	4.615 72E-80	0.000 586 517
	标准差	0	2.869 39E-82	2.528 14E-79	0.000 606 787
	最优值	0	0	1.271 3E-162	7.679 25E-06
F4	平均值	9.944 19E-05	0.000 395 391	0.001 070 601	0.001 842 668
	标准差	9.660 35E-05	0.000 383 572	0.000 593 764	0.001 050 03
	最优值	5.301 48E-06	3.755 83E-05	0.000 236 88	0.000 575 546
F5	平均值	-3 364.002 543	-3 370.668 638	-3 499.742 149	-3 140.779 172
	标准差	278.325 017 3	252.931 902 7	429.729 841 5	247.354 862 9
	最优值	-3 952.952 189	-3 735.803 467	-4 189.780 245	-3 498.935 865
F6	平均值	0	0	5.633 930 203	2.323 083 359
	标准差	0	0	2.881 832 471	4.851 199 11
	最优值	0	0	0	1.989 918 365

从表 1 可见,在函数 $F_1 \sim F_3$ 中,MSISSA、SSA 的最优值均为这三个函数最优,表明 MSISSA、SSA 性能优于 PSO、DBO。与其他算法相比,MSISSA 的标准差最小。表明在寻优精度、稳定性方面,MSISSA 均优于其他算法。在函数 $F_4 \sim F_6$ 中,在求解 F_4 时,MSISSA 的最优值、平均值是最接近函数最优值,其标准差最小,表明该算法具有较强的寻优能力;对于函数 F_5 ,在平均值、标准差方面,MSISSA 的优越性未体现出来;对于函数 F_6 的求解,MSISSA、SSA 的平均值、标准差均为 0,表明这两种算法在寻优能力方面相同。总体来看,与其他三种算法相比,MSISSA 的寻优能力更强。

3.2 齿轮箱故障诊断实验

3.2.1 齿轮箱振动信号处理

选取东南大学故障数据集的第四列数据作为诊断数据,采用滑动窗口的方式进行数据划分,设置滑动窗口大小为 2 048,滑动步长为 1 000。重构之后每种类型的样本为 200 个,一共 1 000 个样本,每个样本设置 2 048 个点。

利用 VMD 对齿轮箱振动信号进行处理,VMD 的模式参数 K 过小会导致不同频率成分混合,过大则可能引入噪声或虚假分量。使用中心频率法来确定 K 值。以第一种故障样本数据为例,IMF 在不同 K 值下的中心频率如表 2 所示,在 $K=3,4$ 时,中心频率有着较大的幅度变化,表示信号分解不完全,直到 K 为 11 时,出现中心频率 4 217 Hz 和 4 435 Hz 近似,由此判定 K 值取 10。

表 2 各 IMF 分量中心频率

中心频率	IMF1	IMF2	IMF3	IMF4	IMF5	IMF6	IMF7	IMF8	IMF9	IMF10	IMF11
3	27	1 847	3 714								
4	25	1 273	2 529	3 874							
5	27	1 173	1 928	3 566	4 303						
6	26	1 108	1 854	2 544	3 650	4 366					
7	26	703	1 467	1 984	3 310	3 809	4 415				
8	25	667	1 249	1 900	2 513	3 361	3 869	4 442			
9	26	661	1 215	1 853	2 287	3 273	3 659	4 057	4 494		
10	25	645	1 131	1 559	1 951	2 511	3 290	3 712	4 153	4 514	
11	25	635	1 086	1 482	1 900	2 406	3 133	3 411	3 806	4 217	4 435

将分解出的 IMF 前五个分量进行时频域分析,如图 1、图 2 所示。

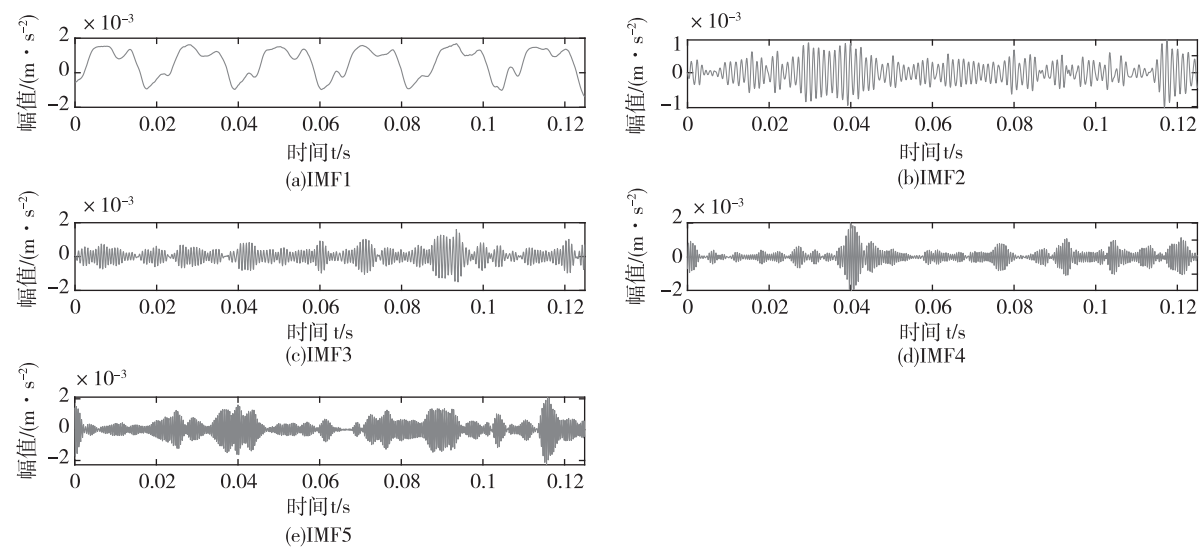


图 1 前五个 IMF 分量时频图

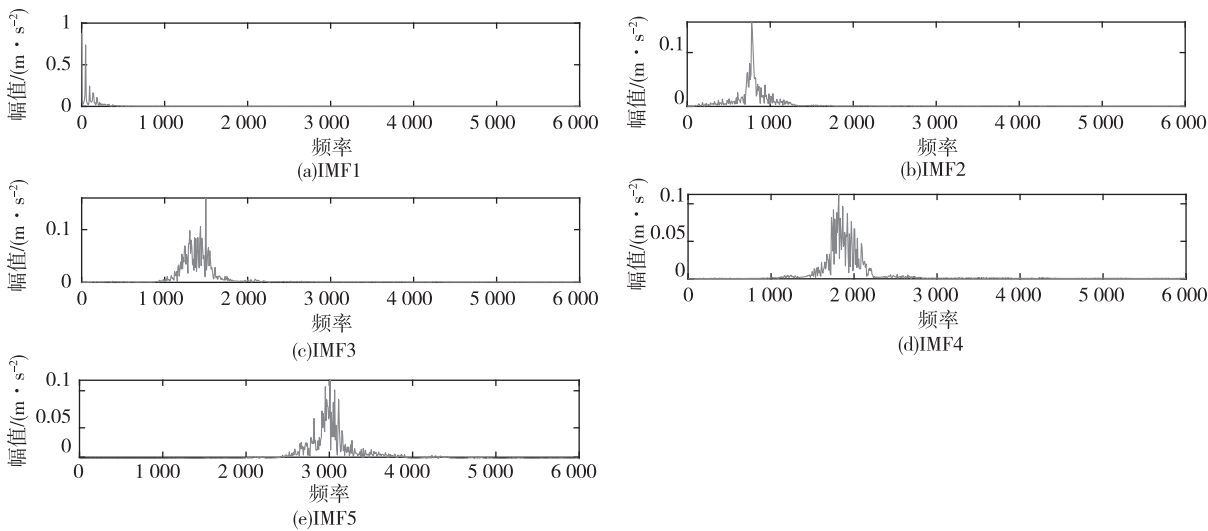


图 2 前五个 IMF 分量频谱图

3.2.2 MSISSA – SVM 故障识别

在经过 VMD 提取齿轮箱的特征向量后,把每个样本的包络谱熵最小的 IMF 分量,对其均值、方差、峰值、峭度、有效值、峰值因子、脉冲因子、波形因子和裕度因子 9 个指标进行计算,用这 9 个指标构建每个样本的特征向量。第 10 个指标为齿轮箱故障标签,其中齿轮状态标签为 1,正常状态标签为 2,断齿故障标签为 3,根裂纹故障标签为 4,齿面磨损故障标签为 5。每种有 200 个样本,将其中 120 个划分为训练样本,80 个划分为测试样本。最后,将特征值向量送入 MSISSA – SVM 进行齿轮箱故障分类。

在实验初始化阶段,MSISSA 的种群数量设置为 50,迭代最大次数为 200。发现者、警戒者均占种群的 20%,ST 设为 0.8。经 MSISSA 优化后,SVM 的 c 值为 35.89,g 值为 31.975。其故障诊断

的实验结果如图 3 所示。




图 3 MSISSA – SVM 分类混淆矩阵图

图 3 为 MSISSA-SVM 模型的分混淆矩阵,纵轴为真实标签,横轴为预测标签,由图可知,MSISSA-SVM 模型在齿轮箱断齿和根裂纹故障中均出现 2 个错误,准确率均为 97.5%。在健康状况和齿面磨损故障下出现 1 个错误,准确率均为 98.8%。在断齿故障中,诊断准确无误,该模型对齿轮箱 5 种故障总体诊断准确率高达 98.5%。

3.2.3 不同故障诊断模型对比分析

为验证所提出模型的有效性,分别建立 PSO-

SVM、DBO-SVM、SSA-SVM 与所提出的诊断模型进行对比实验,统一利用 VMD 处理原始信号后进行信号重构,将重构信号输入四种不同的分类模型进行分类。四种分类模型的准确率对比如图 4 所示,所提模型分类准确率为 98.5%,为四种方法中准确率最高。

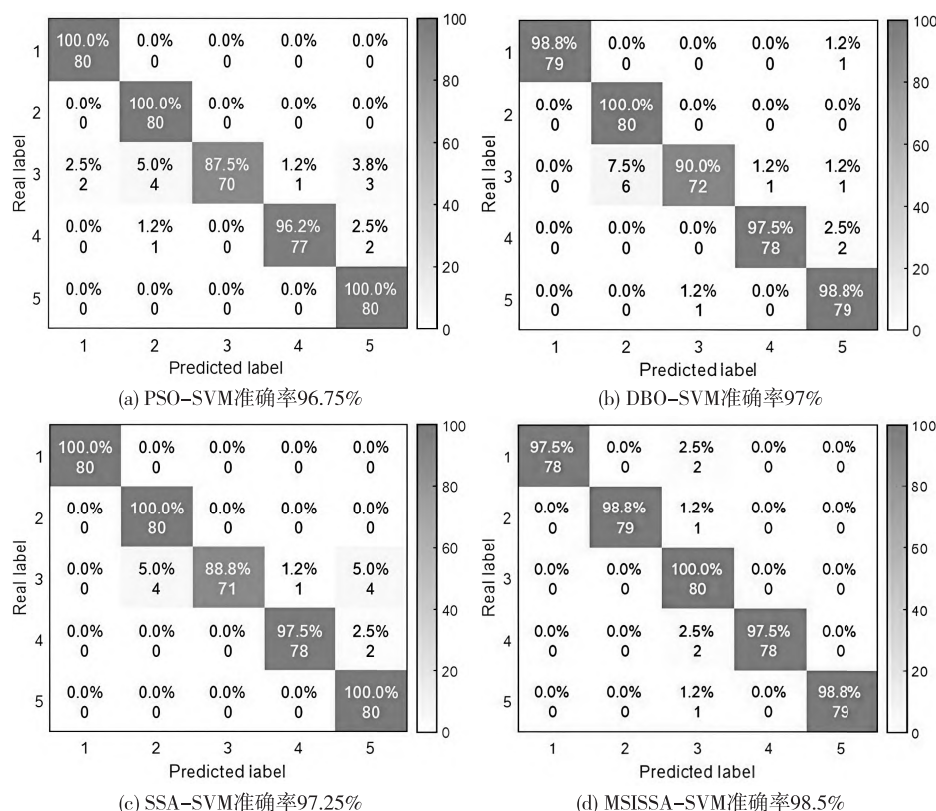


图 4 四种分类器准确率对比混淆矩阵

为测试所提模型的泛化能力,对每种模型在相同的训练集和测试集比例条件下独立进行十次实验后取平均值,诊断结果如表 3 所示。

表 3 四种分类器结果对比

诊断模型	平均准确率	最佳准确率
PSO-SVM	0.965 0	0.982 5
DBO-SVM	0.972 5	0.985 0
SSA-SVM	0.978 6	0.985 0
MSISSA-SVM	0.987 5	0.997 5

由表 3 可见,在同等条件下,所提出经过 MSISSA 优化的 SVM 模型相较于 PSO-SVM、DBO-SVM 和 SSA-SVM,平均准确率分别提高了 2.25%、1.5% 和 0.89%,验证了所改进的 MSISSA 算法的

优越性和良好的泛化性能。

4 结论

为改善 SSA 的寻优性能,本研究采用拉丁超立方策略、自适应权重因子、可变螺旋搜索及莱维飞行策略对其进行改进,提升了算法的全局搜索能力和收敛速度。通过将 MSISSA 与 SVM 相结合,实现对 SVM 模型中超参数的寻优,并利用 VMD 分解齿轮箱振动信号,成功提取多尺度特征,在此基础上构建了 VMD-MSISSA-SVM 故障诊断模型。实验结果表明,该模型具有高诊断精度和良好的鲁棒性,可以有效地识别不同类型的齿轮箱故障,验证了其在实际应用中的可行性和优越性,为复杂机械系统的健康监测提供了有效解决方案。

参考文献:

- [1] 张龙,甄灿壮,易剑昱,等. 双通道特征融合 CNN-GRU 齿轮箱故障诊断[J]. 振动与冲击,2021,40(19):239-245.
- [2] WANG Z, HE G, DU W, et al. Application of parameter optimized-variational mode decomposition method in fault diagnosis of gearbox[J]. IEEE Access, 2019(7):44871-44882.
- [3] 徐志祥,玄永伟,王洪洋,等. 基于 VMD-CNN-BiTCN 滚动轴承故障诊断[J]. 微特电机, 2025, 53(2): 68-73.
- [4] 赵化彬,张志杰. 基于本征模态函数最优配比的冲击波信号经验模态分解降噪方法[J]. 科学技术与工程, 2017,17(18):231-237.
- [5] 闫鹏,张云鹏,周倩倩,等. 基于改进 EMD 的爆破振动信号降噪方法研究[J]. 振动与冲击, 2025, 44(1): 212-220.
- [6] ZHAO Y, FAN Y, LI H, et al. Rolling bearing composite fault diagnosis method based on EEMD fusion feature[J]. Journal of Mechanical Science and Technology, 2022, 36(9):4563-4570
- [7] 高川,苏淑靖. 基于 VMD 和 POA-SVM 的滚动轴承故障诊断[J]. 微电机,2024,57(10):42-47,61.
- [8] 蔡铮印,鹿雷,丛岫. 基于自适应 VMD 与 IAO-SVM 的滚动轴承故障诊断[J]. 黑龙江大学工程学报(中英文),2024,15(4):47-54.
- [9] 戚晓利,杨艳,崔创创,等. 基于 RTSWMFE,IS-GSE 与 COOT-SVM 的行星齿轮箱故障诊断[J]. 振动. 测试与诊断,2025,45(1):132-139.
- [10] 李国友,杨梦琪,杭丙鹏,等. 基于模糊粗糙集和鲸鱼优化支持向量机的化工过程故障诊断[J]. 振动与冲击,2022,41(2):177-184.
- [11] 石延辉,杨洋,廖毅,等. 基于改进粒子群算法优化 SVM 的变压器故障诊断[J]. 武汉大学学报(工学版),2023,56(10):1238-1244.
- [12] 张叶凯,胡亮,丰亚辉,等. 基于 TSO 优化 SVM 的滚动轴承故障诊断[J]. 煤矿机械,2023,44(12):168-172.
- [13] 王博,南新元. 基于 AO-VMD 和 IAO-SVM 的齿轮箱故障诊断[J]. 机械传动,2023,47(5):143-149.
- [14] 顾明亮,李旻. 基于动态调整惯性权重的混合粒子群算法[J]. 计算机与现代化,2018(6):25-29.

[责任编辑 王建蕊]

(上接第 80 页)

5 结语

本文基于 Pixhawk 开源自驾仪,设计搭建了一辆自主巡航车系统。通过对 Pixhawk 开源自驾仪的研究和参数配置,结合直流电机、舵机、多传感器模块以及相关软件的集成,构建了一个具备一定自主性和智能化的无人巡航车。该系统实现了无人巡航车的基本运动控制、定位巡航以及与地面站远程通信等功能。从室外自主巡航实验结果可以看出,无人巡航车能够根据预设的航点完成巡航任务,后续工作将考虑搭载激光雷达、双目摄像头等传感器,实现无人巡航车的厂区巡检的自主避障功能。

参考文献:

- [1] 曹琴. 基于 APM 飞控技术的校园无人巡航车的设计与实现[D]. 西安:西京学院,2017.
- [2] 李姗姗,陈小波,石冬剑. 基于 PX4 的无人物流车远程监控与控制系统设计[J]. 电脑编程技巧与维护,2024(12):88-91.
- [3] 吴叶凡. 无人巡检车全天候守护道路安全[N]. 科技日报,2024-11-13(6).
- [4] 贾余晋. VSLAM 技术在室内自主巡航车上的应用研究[D]. 西安:西京学院,2021.
- [5] 刘娜. 疫情下的无人配送:京东美团加速落地 初创公司或现融资潮[EB/OL]. 新浪财经, [2024-01-19]. <https://finance.sina.com.cn/8haolou/2020-03-06/doc-iimxxstf6817797.shtml>.
- [6] 孙添飞,唐臣玉,陈仕聪,等. 低速无人车产业化发展的现状分析[J]. 中国标准化,2024(15):100-107.
- [7] 方淑娟,李子琦. 基于 ROS 和 Pixhawk 飞控自驾仪的无人清扫船研究[J]. 现代制造技术与装备,2023,59(7):188-190.
- [8] ArduPilot. ArduPilot: Open source autopilot software[EB/OL]. [2025-01-17]. <https://ardupilot.org>.
- [9] PX4 Autopilot. [EB/OL]. [2025-01-18]. <https://px4.io/>.
- [10] 古训,田洪兴. 基于 APM 自驾仪的四旋翼飞行控制系统设计[J]. 贵阳学院学报(自然科学版),2015,10(4):18-21.

[责任编辑 莫昌琍]